

P.I.M.S : Projet à l'Interface mathématiques et sciences de la vie

Analyse géométrique des protéines

Rapport rédigé par Louane Bessard et Louis Roussange
Projet commun avec Cylia Grand, Gaspard Riondet et Romain Petitjean
Supervisé par Philippe Malbos, Celine Brochier Armanet et Jules Fauchon

Résumé

Matériel : Codes PDB de 152 protéines - nous ne devons étudier que leur séquence en AA et pas leur séquence génomique.

Problématique n°1 Identifier les Globines parmi ces protéines.

Problématique n°2 Recréer l'arbre phylogénétique associé à ces protéines et tenter de le recréer à partir de l'analyse topologique des structures 3D des protéines.

1. Première partie Introduction

Dans le cadre de cette étude, nous disposons d'un jeu de données constitué de 152 séquences protéiques provenant de différents animaux. Pour chaque protéine, deux types d'informations sont fournis : d'une part les fichiers PDB, qui décrivent la structure tridimensionnelle de la molécule, et d'autre part les fichiers FASTA, qui contiennent la séquence en acides aminés. L'objectif principal est de déterminer si ces protéines appartiennent toutes à la famille des globines, un ensemble de protéines bien connues pour leur capacité à lier l'oxygène grâce à un groupement hème. Cette première question est essentielle, car le jeu de données pourrait contenir des protéines d'autres familles, ce qui nécessiterait une étape de filtrage ou de classification préalable. Si certaines de ces protéines correspondent effectivement à des globines, un second enjeu consiste à savoir s'il est possible de distinguer différents sous-groupes au sein de cette famille. Les globines regroupent en effet plusieurs classes fonctionnelles et évolutives comme l'hémoglobine, la myoglobine, la neuroglobine ou la cytoglobine. Il est pertinent d'examiner si ces sous-groupes peuvent être mis en évidence à partir des seules informations de séquence ou de structure. Cette distinction pourrait révéler des proximités évolutives, des différences fonctionnelles ou des signatures structurales caractéristiques. L'objectif est d'identifier des motifs, des similarités ou des divergences permettant de regrouper les protéines et de caractériser leur appartenance éventuelle à des sous-familles de globines. Ce travail est ainsi destiné à automatiser l'extraction des données pertinentes, à comparer les structures, et à produire des visualisations ou des regroupements permettant de répondre de manière précise aux questions posées.

1.1 Motivation : biologie

Les globines constituent une large famille de protéines liant l'oxygène, présentes chez la plupart des organismes vivants. Sur le plan fonctionnel, les globines jouent un rôle essentiel dans le transport, le stockage et la détection de l'oxygène. Chez les vertébrés, les exemples les plus connus sont : l'hémoglobine, qui transporte l'O₂ dans le sang, la myoglobine, qui stocke l'O₂ dans les muscles. Outre ces deux protéines classiques, de nombreuses globines dites non conventionnelles (neuroglobine, cytoglobine, globines bactériennes...) remplissent des fonctions variées, notamment dans la réponse au stress oxydatif ou la signalisation cellulaire. La plupart des globines font 150 acides aminés de long. Elles partagent toutes une structure tridimensionnelle caractéristique, appelée repliement globine, composée de huit hélices *alpha* (de A à H) organisées autour d'un groupement hème capable de fixer des gaz comme l'oxygène, le dioxyde d'azote ou le monoxyde de carbone. D'un point de vue évolutif, les globines forment une famille multigénique ancienne, issue de duplications successives. Cette diversification a permis l'apparition de fonctions spécialisées et l'adaptation des organismes à des environnements très différents. Grâce à leur conservation structurale, les globines constituent un modèle privilégié pour étudier les relations entre structure, fonction et évolution des protéines.

1.2 Contributions principales

- Développement d'une pipeline d'analyse géométrique pour l'étude des protéines
- analyse d'un jeu de données de 152 protéines
- comparaison des résultats obtenus avec les données de référence issues d'un arbre phylogénétique

2. Méthodologie

2.1 Données et préparation

Description des bases de données protéiques, critères de sélection. Les structures ont été extraites de la Protein Data Bank (PDB)

2.2 modélisation in silico : mathématiques

Aujourd'hui, les données scientifiques présentent souvent une géométrie complexe. Elles sont très variées mais aussi dimensionnelles. Les méthodes classiques ne suffisent pas toujours pour comprendre leur structure glo-

bale, qu'il s'agisse de formes tridimensionnelles, de signaux, de trajectoires ou encore de structures moléculaires. C'est notamment le cas dans notre étude qui porte sur l'analyse géométrique des protéines.

La **Topological Data Analysis (TDA)** propose d'utiliser la topologie pour analyser les structures tridimensionnelles des protéines. L'objectif est d'observer des motifs globaux (composantes connexes, cycles, cavités) que les méthodes classiques ne détectent pas nécessairement. Cette approche utilise un ensemble de méthodes mathématiques, statistiques et algorithmiques rigoureuses afin d'extraire, d'analyser et d'exploiter les structures topologiques et géométriques sous-jacentes aux données initiales.

L'**homologie persistante** constitue l'un des piliers de la TDA. Cette approche permet notamment de comparer les structures protéiques entre elles indépendamment de leurs fonctions biologiques.

Dans un premier temps, la démarche débute par un prétraitement de données afin que les représentations protéiques prennent la forme de *nuages de points*, généralement dans des espaces euclidiens.




FIGURE 1 – Simplexes de dimension 0 à 3

Pour appliquer l'homologie persistante aux données et en extraire les motifs globaux, il faut reconstruire une structure continue à partir du nuage de points. C'est exactement ce que permettent les **complexes simpliciaux**.

La construction de ces objets combinatoires repose notamment sur deux constructions fondamentales en topologie algébrique appliquée :

- le complexe de Čech
- le complexe de Vietoris–Rips

Dans le **complexe de Čech**, pour chaque point x , on dessine une boule de rayon r autour de lui. Les points forment un simplexe (segment, triangle, tétraèdre, etc.) si et seulement si toutes ces boules ont une intersection commune. Formellement, un ensemble σ appartient à $\check{C}ech(r)$ si l'intersection des boules $B_x(r)$ pour x dans σ est non vide :

$$\check{C}ech(r) = \left\{ \sigma \in S \mid \bigcap_{x \in \sigma} B_x(r) \neq \emptyset \right\}$$

Le **complexe de Vietoris–Rips**, quant à lui, repose uniquement sur les distances : un simplexe appartient au complexe si tous les points qui le composent sont à

distance inférieure ou égale à $2r$ les uns des autres :

$$\text{Vietoris-Rips}(r) = \{ \sigma \in S \mid \text{diam}(\sigma) \leq 2r \}$$

On a les relations classiques :

$$\check{C}ech(r) \subset \text{Vietoris-Rips}(r) \subset \check{C}ech(\sqrt{2}r)$$

ce qui montre que Vietoris–Rips constitue une approximation du complexe de Čech.




FIGURE 2 – Différents complexes Vietoris-Rips construits pour un ensemble de données sont présentés dans (a) à (d)

Ces deux **filtrations** consistent à construire une suite de complexes simpliciaux croissants et à suivre la naissance et la mort des caractéristiques topologiques constituées par les motifs globaux énoncés précédemment.

Les **nombre de Betti** (β_k) sont les dimensions de ces motifs.

- Cercle : $\beta_0 = 1, \beta_1 = 1$
- Sphère : $\beta_0 = 1, \beta_1 = 0, \beta_2 = 1$
- Tore : $\beta_0 = 1, \beta_1 = 2, \beta_2 = 1$




FIGURE 3 – Nombre de Betti du point, du cercle, d'une sphère et d'un torus

L'idée centrale de l'homologie persistante est d'observer comment ces caractéristiques topologiques apparaissent

et disparaissent lorsque l'on fait croître un paramètre, généralement un rayon r . À mesure que r augmente, des composantes apparaissent (naissance), se fusionnent (mort), mais aussi des boucles apparaissent (naissance), puis se remplissent (mort), et ainsi de suite.

On enregistre leur naissance et leur mort. Nous obtenons des graphiques appelés **barcode** et **diagramme de persistance**, constitués respectivement d'un ensemble de segments ou d'un ensemble de points dans le plan, représentant les différentes caractéristiques topologiques de dimension zéro, un ou deux. Les longs intervalles correspondent à des structures robustes et significatives, tandis que les courts traduisent du bruit.




FIGURE 4 – Barcode de persistance et diagramme de persistance d'une fonction $f : [0,1] \rightarrow \mathbb{R}$

Vient ensuite l'étape de vectorisation pour transformer les diagrammes de persistance en des représentations vectorielles via des transformateurs qui peuvent être des résumés, des fonctions ou des noyaux. Cette vectorisation facilite l'extraction d'invariants topologiquement utilisés ensuite lors de l'application de méthodes d'apprentissage statistiques pour la classification des protéines. Nous avons par exemple les **paysages de persistance** qui sont une collection de fonctions continues et linéaires par morceaux qui résume les diagrammes de persistance.

La TDA s'appuie également sur des distances avancées telles que les **distances de Bottleneck** ou **Wasserstein**. Il est nécessaire de doter les espaces des barcodes et des diagrammes de persistance par des structures métriques afin de pouvoir les comparer. La distance de Bottleneck est la plus fondamentale d'entre elles. Voici sa définition :

On cherche à appairer de la meilleure façon possible les points du premier diagramme avec ceux du second. Pour chaque appariement on regarde la distance maximale entre deux points appariés. D'où la distance de Bottleneck est la distance la plus petite possible de ces distances maximales.

$$d_B(D_1, D_2) = \inf_{\gamma} \sup_{x \in D_1} \|x - \gamma(x)\|_{\infty}$$

La distance de Wasserstein est quant à elle plus fine, plus sensible, et plus informative que la bottleneck : elle mesure la somme des écarts entre points appariés dans

deux diagrammes, en pénalisant toutes les différences. Pour chaque appariement on calcule la somme des distances entre points appariés, puis on prend la plus petite somme possible.

$$W_p(D_1, D_2) = \left(\inf_{\gamma} \sum_{x \in D_1} \|x - \gamma(x)\|_{\infty}^p \right)^{1/p}$$

2.3 Outils computationnels

Langages, bibliothèques, paramètres spécifiques. L'analyse a été réalisée en Python avec les bibliothèques NumPy, SciPy et Biopython. Les visualisations ont été générées avec Matplotlib.

1 Seconde Partie : TDA

L'analyse topologique des données (TDA) permet d'extraire des caractéristiques géométriques et topologiques d'un nuage de points. Pour une protéine, les positions des atomes C_{α} forment un nuage de points dans $\mathbb{R}^3$. En construisant un complexe de Čech paramétré par un rayon r , on obtient un diagramme de persistance qui résume l'apparition et la disparition de cavités topologiques (composantes connexes, boucles, poches). La distance de Wasserstein permet alors de quantifier la dissimilarité entre deux diagrammes, donc entre deux protéines.

2 Formule intégrale de la distance de Wasserstein

Définition 1 (Espace mesuré) *Un espace mesuré est un triplet $(X, \mathcal{A}, \mu)$ où :*

- X est un ensemble (non vide)
- $\mathcal{A}$ est une **tribu**
- $\mu : \mathcal{A} \rightarrow [0, +\infty]$ est une **mesure**

Définition 2 (Tribu et mesure) *Une tribu $\mathcal{T}(X)$ est une famille de parties de X stable par complémentaire ($A \mapsto A^c$) et par réunion dénombrable ($\bigcup_n A_n$).*

Une mesure μ est σ -additive :

$$\mu\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} \mu(A_i) \quad \mu(\emptyset) = 0$$

pour tout ensemble d'indices I dénombrable (fini ou en bijection avec $\mathbb{N}$).

Si $\mu(X) = 1$, μ est une mesure de probabilité.

Définition 3 (Distance de Wasserstein W_p)

Soient μ et $\nu \in \mathcal{P}(X)$ deux mesures. Pour $p \geq 1$, la distance de Wasserstein d'ordre p est définie par :*

$$W_p(\mu, \nu) = \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{X \times X} d(x, y)^p d\pi(x, y) \right)^{1/p}$$

*où $\Pi(\mu, \nu)$ est l'ensemble des **couplages** (ou transports), c'est-à-dire des mesures de sur $X \times X$ dont les marginales sont μ et ν .*

*les deux mesures doivent être soit des mesures de probabilités, ou alors les couplages les couplages peuvent être vides si les mesures totales sont différentes. Il est aussi possible de normaliser au préalable les mesures, voire d'employer la formule de la distance de wasserstein non normalisée, inadaptée dans le cadre de ce projet.

La distance de wasserstein représente le coût total du transport de la masse de μ vers ν , chaque élément de masse étant déplacé selon la distance $d(x, y)$.




FIGURE 5 – Exemple de distance de transport optimal entre deux lois normales.

Définition 4 (Mesure produit) Soient $(X, \mathcal{A}, \mu)$ et $(Y, \mathcal{B}, \nu)$ deux espaces mesurés. La **mesure produit** notée $\mu \otimes \nu$ ou $\mu \times \nu$ est l'unique mesure sur $(X \times Y, \mathcal{A} \otimes \mathcal{B})$ satisfaisant : $\forall A \in \mathcal{A}, \forall B \in \mathcal{B}$, $(\mu \otimes \nu)(A \times B) = \mu(A) \cdot \nu(B)$ où $\mathcal{A} \otimes \mathcal{B}$ est la tribu produit engendrée par les rectangles $A \times B$.

Définition 5 (Mesure marginale) Soit Π une mesure sur l'espace produit $X \times Y$.

La **première marginale** de Π est la mesure μ sur X définie par : $\forall A \subset X, \mu(A) = \Pi(A \times Y)$

La **seconde marginale** de Π est la mesure ν sur Y définie par : $\forall B \subset Y, \nu(B) = \Pi(X \times B)$

On dit que Π est un **couplage** entre μ et ν si ses marginales sont μ et ν .

Une mesure de couplage n'est une mesure produit, sauf si les deux marginales sont indépendantes,

c. a. d. si $\Pi(A \times B) = \mu(A)\nu(B), \forall A \in \mathcal{A}, \forall B \in \mathcal{B}$

Définition 6 (Tribu des singletons et dirac) Sur l'ensemble discret $\{1, \dots, n\}$, la tribu associée à la mesure de Dirac est la tribu des **singletons** : $\mathcal{P}(\{1, \dots, n\})$. Pour toute partie A , $\delta_i(A) = 1$ si $i \in A$ et 0 sinon.

Dans notre contexte, les diagrammes de persistance sont des ensembles finis de points. Chaque point (b, d) du diagramme (birth b , death d) représente une caractéristique topologique issue de sa dimension $k \in \{0, 1, 2\}$.

Un diagramme $D = \{(b_i^{(k)}, d_i^{(k)})\}_{i=1}^{n_k}$ est muni de la mesure empirique :

$$\mu_D^{(k)} = \frac{1}{n_k} \sum_{i=1}^{n_k} \delta_{(b_i^{(k)}, d_i^{(k)})} \text{ et } \mu_D = \sum_{k=0}^2 \frac{n_k}{n} \mu_D^{(k)}$$

où $\delta_{(b,d)}$ est la masse de Dirac au point (b, d) .

et où $n = \sum_{k=0}^2 n_k$ (pour normaliser la mesure μ_D)

Définition 7 (Vecteur de persistance) le Vecteur associé au complexe de Čech obtenu à partir de la position dans le plan 3d des carbones alphas issus d'un fichier .pdb de protéine se présente de la façon suivante après filtration, identification des simplexes et extraction des persistances : On note :

$$v = [(k, v_i)] \text{ avec } k \in \{0, 1, 2\} \text{ et } i \in \{1, \dots, m_k\}$$

k est la dimension d'homologie (0 pour les composantes connexes, 1 pour les boucles, 2 pour les cavités etc.) c'est le nombre de Betti. v_i est la i -ème valeur de persistance tel que $v_i = (b_i, d_i)$, et m_k est le nombre de points dans le diagramme de persistance de dimension k . avec $(\sum_{k=0}^2 m_k) = \text{card}(v)$

Lien avec la formule intégrale :

Lorsque $\mu = \sum_{i=1}^n \delta_{x_i}$ et $\nu = \sum_{j=1}^m \delta_{y_j}$, le problème de transport optimal continu se réduit à un problème d'affectation linéaire, d'où l'expression par somme. La diagonale joue le rôle d'un "réservoir" permettant d'égaliser les masses.

Définition 8 Espace ℓ^p

Soit $p \in [1, +\infty]$. L'espace ℓ^p est l'ensemble des suites (ou vecteurs) $x = (x_1, x_2, \dots)$ à valeurs réelles dont la norme ℓ^p est finie.

$$\text{Pour } 1 \leq p < \infty : \ell^p = \left\{ x \mid \|x\|_p = \left(\sum_{i=1}^{\infty} |x_i|^p \right)^{1/p} < \infty \right\}$$

$$\text{Pour } p = \infty : \ell^\infty = \{x \mid \|x\|_\infty = \sup_i |x_i| < \infty\}$$

Définition 9 (Distance de Wasserstein discrète sur $\mathbb{R}^2$)

Pour $v_1 = \{(x_i)\}_{i=1}^n$ et $v_2 = \{(y_j)\}_{j=1}^m$, deux ensembles discrets de $\mathbb{R}^2$, la distance de Wasserstein p, q s'écrit pour $p < \infty$, respectivement $p = \infty$:

$$W_{p,q}(v_1, v_2) = \left(\min_{\gamma} \sum_{x \in v_1} \|x - \gamma(x)\|_q^p \right)^{1/p}$$


$$W_{\infty,q}(v_1, v_2) = \left(\min_{\gamma} \left(\sup_{x \in v_1} \|x - \gamma(x)\|_q \right) \right)$$

où γ est un appariement entre les points de v_1 et ceux de v_2 , permettant l'appariement à la diagonale $\{(x, x) \mid x \in \mathbb{R}\}$ des éléments sans paire associée pour le cas où les cardinaux sont différents par exemple.

pour un appariement γ fixé, on obtient un vecteur de ℓ^q des distances $\|a - \gamma(a)\|_q$

bien sûr v_1 et v_2 sont des ensembles finis, de norme finie, $W_{p,q}(v_1, v_2) = +\infty$ n'ayant pas de sens mathématique. De même pour le vecteur des appariements.

Exemple de distance de transport optimal entre deux diagrammes de Čech :



Propriétés de la distance de Wasserstein, pour toutes mesures μ, ν, λ :

Propriété 1 (Positivité et séparation)

$W_p(\mu, \nu) \geq 0$ et $W_p(\mu, \nu) = 0 \iff \mu = \nu$.

Propriété 2 (Symétrie)

$W_p(\mu, \nu) = W_p(\nu, \mu)$.

Propriété 3 (Inégalité triangulaire)

$W_p(\mu, \nu) \leq W_p(\mu, \lambda) + W_p(\lambda, \nu)$.

3 Application à 152 protéines, matrice de comparaison

Nous avons calculé la distance de Wasserstein entre les 152 protéines, à partir de leurs diagrammes de persistance en dimension 1 uniquement*. La matrice de comparaison M de taille 152×152 avec $M_{ij} = W_2(P_i, P_j)$ la distance de wasserstein discrète sur ℓ^2 notée W et $P_i, i \in [1; 152]$ la i ème protéine.

*Dimension 1 : informe sur les cavités (sites actifs), tunnels (canaux ioniques), et boucles (sites d'interactions)
Dimension 0 : pour la structure globale et les composantes connexes, il y en a une seule pour les monomères.
Dimension 2 : informe sur la présence et la taille des cavités fermées.

les combinaisons des trois dimensions sont très gourmandes en mémoire et la dimension 1 étant la plus informative c'est celle que nous utiliserons pour la suite.

3.1 matrice de comparaison de distances

$M \in M_{n^2}(\mathbb{R}^+)$ et $i, j, k \in [1; n]$

Propriété 4 (Symétrie) $\forall i, j, M_{ij} = M_{ji}$.

Cela découle directement de la symétrie de la distance.

Propriété 5 (Diagonale nulle) $\forall i, M_{ii} = 0$.

Propriété 6 (Inégalité triangulaire matricielle)

$\forall i, j, k, M_{ik} \leq M_{ij} + M_{jk}$. Cette propriété est héritée de l'inégalité triangulaire de W_2 .

Propriété 7 (colonnes et lignes égales) :

la k^{ime} colonne notée $\{M_{i,k}, \forall i\}$

la k^{ime} ligne notée $\{M_{k,j}, \forall j\}$

le k^{ime} 'coude' $_+$ noté $\{M_{k,j}, \forall j > k\} \cup \{M_{i,k}, \forall i > k\}$


le k^{ime} 'coude' $_-$ noté $\{M_{k,j}, \forall j < k\} \cup \{M_{i,k}, \forall i < k\}$ contiennent les mêmes sous éléments de M , du fait de sa symétrie et ce $\forall k$.

TABLE 1 – Matrice de distance W_2 pour n protéines avec $i, j \in [1, n]$

	P_1	P_2	$\dots$	P_i	$\dots$	P_n
P_1	0	w_{12}	$\dots$	w_{1i}	$\dots$	w_{1n}
P_2	w_{12}	0	$\dots$	w_{2i}	$\dots$	w_{2n}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
P_i	w_{1i}	w_{2i}	$\dots$	0	$\dots$	w_{in}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
P_n	w_{1n}	w_{2n}	$\dots$	w_{in}	$\dots$	0

Avec $w_{ij} = W(P_i, P_j)$ et $w_{ij} = w_{ji}$ par symétrie.

voici la matrice obtenue expérimentalement, avec une échelle de coloration normalisée améliorant sa visibilité, nous garderons cette échelle pour l'affichage de toutes les matrices :



4 Ordonnancement des protéines


4.1 Définition du problème

L'objectif est d'ordonner ces protéines selon leur similarité structurale, c'est-à-dire de placer en début de matrice réorganisée les protéines similaires par changement de base.

Nous possédons un arbre phylogénétique de référence obtenu à partir des informations trouvées sur PDB à partir des codes des 152 protéines à étudier, que Romain et Cylia nous ont partagé.



Cet arbre a été traduit en matrice cophénique en évaluant les distances évolutives entre espèces par une distance cophénique qui est ultramétrique, une inégalité plus forte que l'inégalité triangulaire faisant que les trois plus grandes distances entre trois éléments sont toujours égales. Une fois cette matrice obtenue, nous pouvons la comparer à la matrice triée contenant les distances de wasserstein par calcul du coefficient de corrélation de mantel. Nous avons aussi observé visuellement l'arbre obtenu par tri de la matrice de wasserstein obtenu par l'opération squareform qui retourne un vecteur contenant les distances du triangle supérieur de la matrice initiale, ce qui grâce à l'algorithme UGMPA retourne l'arbre associé. Ensuite les deux arbres sont comparables avec trois méthodes principales : le taux de conservation des relations père-fils, la comparaison des profondeurs des feuilles ou encore la méthode de Robinson-Foulds. Pour comparer deux matrices entre elles, nous nous intéresserons aux coefficients de corrélation de Pierson et de Mantel.



Il est important de noter que l'on ne s'attend pas à retrouver exactement l'arbre phylogénétique de référence

à partir de l'arbre issu des comparaisons des structures 3D des protéines, mais plutôt de s'en approcher puisque nous ne comparons pas les mêmes objets même si ils contiennent la même liste de protéines. De plus, une matrice représente avant tout un graphe et non un arbre, ce qui veut dire qu'il existe plusieurs critères permettant de clusteriser des éléments et nous essayons ainsi de mettre en évidence l'existence ou non d'un lien entre la phylogénie de ces 152 protéines et leur clusterisation en ayant comparé leur structure tridimensionnelle par Wasserstein.

4.2 Régression Linéaire aux Moindres Carrés (RLMC)

4.2.1 Définition

Pour chaque protéine i , on considère la ligne i de la matrice des distances, qui contient les distances entre la protéine i et toutes les autres protéines $j \neq i$: $\mathbf{y}_i = (w_{i,1}, w_{i,2}, \dots, w_{i,i-1}, w_{i,i+1}, \dots, w_{i,n})$

On suppose que ces distances peuvent être modélisées linéairement en fonction de la position j dans la matrice :

$$\hat{y}_j = a_i \cdot j + b_i$$

où a_i est la pente, b_i l'ordonnée à l'origine, et j l'indice de la protéine j , la variable explicative.

4.2.2 Calcul des similitudes par la méthode des moindres carrés

On minimise la somme des carrés des résidus :

$$\min_{a_i, b_i} \sum_{j \neq i} (y_j - (a_i \cdot j + b_i))^2$$

Les solutions sont données par :

$$a_i = \frac{\sum_{j \neq i} (j - \bar{j})(y_j - \bar{y})}{\sum_{j \neq i} (j - \bar{j})^2}, \quad b_i = \bar{y} - a_i \bar{j}$$

où $\bar{j}$ et $\bar{y}$ sont les moyennes des j et des y_j .

4.2.3 Coefficient de détermination R_i^2

Le coefficient de détermination mesure la qualité de l'ajustement du modèle linéaire :

$$R_i^2 = \frac{SSR_i}{SST_i} = 1 - \frac{SSE_i}{SST_i}$$

avec :

- $SST_i = \sum_{j \neq i} (y_j - \bar{y})^2$: somme totale des carrés
- $SSR_i = \sum_{j \neq i} (\hat{y}_j - \bar{y})^2$: somme des carrés expliquée
- $SSE_i = \sum_{j \neq i} (y_j - \hat{y}_j)^2$: somme des carrés des erreurs

Le coefficient R_i^2 est compris entre 0 et 1. Plus il est proche de 1, meilleure est la corrélation linéaire, ce qui indique que la protéine i a un comportement similaire aux autres.

Le **taux de similitude** de la protéine i est alors défini par :

$$Score_i = \frac{R_i^2 - R_{\min}^2}{R_{\max}^2 - R_{\min}^2} \times 100$$

ici nous avons obtenu un score de 0% pour la Neuroglobine de Lamproie A0AAJ7TMY1 (code uniprot), gène LOC116948349 et un score de 100% pour la Neuroglobine de Lamproie A0AAJ7T5N9 (code uniprot), gène LOC116943182 - c'est surprenant que les deux outeliens soient issus de la même espèce

4.2.4 Propriétés du vecteur des scores ordonné

Le vecteur des scores ordonné vérifie :

$$R_{(1)}^2 \leq R_{(2)}^2 \leq \dots \leq R_{(n)}^2$$

avec $R_{(1)}^2$ le score minimum (protéine la plus différente) et $R_{(n)}^2$ le score maximum (protéine la plus similaire).

$$\sum_{i=1}^n R_i^2 = 1 \text{ et } \|\mathbf{R}^2\|_1 = \sum_{i=1}^n |R_i^2| = 1$$

4.3 Ordonnement par RLMC



On calcule les scores R_i^2 pour chaque protéine i , puis on trie les indices par ordre décroissant :

indices_{tri} = argsort(R^2) (ordre décroissant- python)


La matrice réorganisée s'obtient par permutation :

$$W_{\text{reorder}} = P \cdot W \cdot P^T$$

où P est la matrice de permutation définie par $P[i, \text{indices}_{\text{tri}}[i]] = 1$.



à partir de cette matrice nous avons créé l'arbre associé par l'algorithme UGMPA



Le taux de conservation de la relation père-fils entre cet arbre et l'arbre de référence étant de 0% nous avons décidé de réaliser un test significatif pour déterminer si l'absence de corrélation entre la distance évolutive et le taux de similitude des structures 3D est due au hasard ou à un problème méthodologique.

4.4 Test de significativité

On veut valider ou rejeter l'hypothèse H_0 suivante : "Il y a une relation entre la position dans la matrice des R^2 ordonnées par ordre croissant et la distance évolutive" et on note H_1 le rejet de H_0 , sa négation.

4.4.1 p-value : statistique de test

Pour chaque régression, on calcule la statistique de test :

$$t_i = \frac{a_i}{SE(a_i)} \sim t(\nu)$$

avec $\nu = n - 2$ degrés de liberté. La p -value est alors donnée par :

$$p_i = 2 \cdot \mathbb{P}(T > |t_i|)$$

4.4.2 Correction de Bonferroni

Lorsque l'on effectue m tests simultanément, le risque d'erreur de type I augmente considérablement :

$$\mathbb{P}(\text{au moins un faux positif}) = 1 - (1 - \alpha)^m$$

Pour $m = n$ tests (un par protéine) et $\alpha = 0,05$, on a :

$$1 - (0,95)^{152} \approx 0,9996$$

soit 99,96% de risque d'avoir au moins un faux positif.

La correction de Bonferroni ajuste le seuil de signification :

$$\alpha_{\text{corrigé}} = \frac{\alpha}{m}$$

Dans notre analyse, 0,159 est la valeur obtenue pour la plus petite p-value en appliquant ce test à l'ensemble des protéines, nous donnant $p_1, \dots, p_n$ p-values. comme $p_i > \alpha_{\text{corrigé}}$ (et $\alpha_{\text{corrigé}} \text{ Vialors } H_0$ est rejetée ce qui veut dire que la méthode par RLMC ne permet pas d'établir de lien entre l'analyse topologique des données et l'analyse phylogénétique des données. Cependant, il existe d'autres méthodes permettant l'ordonnement d'une matrice de similitudes qui pourraient donner de meilleurs résultats. La RLMC nous informe également sur une similitude absolue entre les protéines sans réelle relation d'ordre, l'analyse statistique de la répartition des scores R^2 pourrait nous permettre de discriminer un sous-ensemble de l'échantillon selon une caractéristique structurale. Notre objectif serait d'identifier le sous-ensemble des globines par exemple.

4.5 Distribution de R^2 sous hypothèse nulle

Définition 10 (Loi Bêta) Une variable aléatoire X suit une **loi Bêta** de paramètres $\alpha > 0$ et $\beta > 0$, notée $X \sim \text{Bêta}(\alpha, \beta)$, si sa densité est :

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}, \quad x \in [0, 1]$$

où $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ est la fonction Bêta.

Son espérance est :

$$\mathbb{E}[X] = \frac{\alpha}{\alpha + \beta}$$


Fonction Gamma

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt, \quad z > 0, \quad \Gamma(n+1) = n!$$

$$R^2 \sim \text{Bêta}\left(\frac{1}{2}, \frac{n-2}{2}\right)$$

On a la relation $R^2 = r^2$ où r est le coefficient de corrélation de Pearson. Sous H_0 , la statistique $t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$ suit une loi de Student à $n-2$ degrés de liberté, ce qui implique que r^2 suit la loi Bêta ci-dessus. On l'observe graphiquement (Loi bêta forme décroissante convexe puis

concave) en représentant dans l'ordre croissant ou décroissant les R^2 obtenus :



Par conséquent, l'espérance de R^2 est :

$$\mathbb{E}[R^2] = \frac{\frac{1}{2}}{\frac{1}{2} + \frac{n-2}{2}} = \frac{1}{n-1} = \mu$$

Sous hypothèse nulle, les scores RLMC tendent en moyenne vers $\frac{1}{n-1}$. Un score significativement plus grand indique une corrélation linéaire et donc une structure non aléatoire dans les données.

5 Loi des grands nombres

Soit $(X_n)_{n \geq 1}$ une suite de variables aléatoires réelles, indépendantes et identiquement distribuées (i.i.d.), avec $\mathbb{E}[|X_1|] < +\infty$. On note $\mu = \mathbb{E}[X_1]$. ici on considère que : l'ensemble des scores de RSMD $R_i^2 \forall i \in [1; n]$ où i est l'indice de la protéine P_i étudiée, sont des variables *i.i.d* quitte à ne considérer que la matrice triangulaire supérieure pour éviter les dépendances créées par la relation de symétrie.

5.1 Loi forte des grands nombres

Convergence presque sûre : une suite (Y_n) converge presque sûrement vers Y si : $\mathbb{P}(\lim_{n \rightarrow \infty} Y_n = Y) = 1$. Autrement dit, l'ensemble des ω pour lesquels $Y_n(\omega) \rightarrow Y(\omega)$ a une probabilité de 1.

La **loi forte des grands nombres** énonce que la moyenne empirique converge presque sûrement (ou avec probabilité 1) vers l'espérance :

$$\mathbb{P}(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n R_i^2 = \mu) = 1.$$

On note : $\frac{1}{n} \sum_{i=1}^n R_i^2 \xrightarrow{p.s.} \mu$.

ici l'espérance pour les Scores de RSMD S_i pour la protéine i est de $1/(n-1)$ avec n le nombre de protéines étudiées. Ces convergences ont lieu pour un n grand donc si nous comparons un grand nombre de protéines entre elles.

5.2 Théorème Central Limite (TCL)

Le théorème central limite affirme que la moyenne empirique standardisée converge en loi vers une loi normale :


$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n R_i^2 - \mu \right) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2).$$

5.3 Convergence presque sûre de la densité empirique

Sous des conditions de régularité supplémentaires (notamment une densité continue et bornée), la densité empirique $f_n(x)$ discrète des scores de RMSD converge presque sûrement vers une densité normale théorique continue :

$$f_n(x) = \frac{1}{n} \sum_{i=1}^n (x - R_i^2) \xrightarrow{p.s.} f(x)$$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$



Ici nous avons donc la possibilité d'approcher cet histogramme des scores R^2 par une loi normale, nous permettant d'en retirer la fonction de répartition qui étant donné un seuil noté $r_{seuil\%similitude}$ en paramètre nous donnerait la liste valeurs $(R_i^2, i \in P(\{n\}))$ des protéines sous ce seuil de similitude :

$$\mathbb{P}(X \leq r_{seuil\%similitude}) = \Phi\left(\frac{r-\mu}{\sigma}\right)$$

$$\mathbb{P}(X > r_{seuil\%similitude}) = 1 - \Phi\left(\frac{r-\mu}{\sigma}\right)$$

Φ la fonction de répartition associée

Pour l'étude des Globines, et répondre à la problématique "Toutes les protéines de l'échantillon sont-elles des globines ?" cette méthode ne pourra pas aboutir car (voir section 4.2.3, taux de similitude) Parmi les protéines avec un Score S_i les plus faibles nous retrouvons une neuroglobine. Cette méthode pourrait être utilisée pour discriminer d'autres caractéristiques liées à la structure des protéines mais à ce stade nous ne savons pas encore lesquelles.

5.4 Passage à l'arbre phylogénétique via Neighbor Joining

5.4.1 Algorithme

L'algorithme du Neighbor Joining permet de construire un arbre non enraciné à partir de la matrice des distances :

[H] Neighbor Joining Soit n le nombre de protéines et D la matrice des distances $n > 2$ chaque paire (i, j) Calculer $r_i = \frac{1}{n-2} \sum_{k=1}^n D_{ik}$ Calculer $Q_{ij} = D_{ij} - (r_i + r_j)$ Choisir la paire (i, j) avec Q_{ij} minimal Créer un nouveau nœud u $d_{iu} = \frac{D_{ij} + r_i - r_j}{2}$ $d_{ju} = D_{ij} - d_{iu}$ chaque autre nœud k $D_{uk} = \frac{D_{ik} + D_{jk} - D_{ij}}{2}$ Remplacer i et j par u $n \leftarrow n - 1$

5.4.2 Interprétation de Q_{ij}

La quantité Q_{ij} mesure à quel point i et j sont particulièrement proches l'un de l'autre par rapport à leurs distances aux autres protéines. à chaque itération on choisit la paire avec Q_{ij} minimal car c'est celle qui maximise l'aire des distances minimales et minimise l'aire des distances élevées dans la matrice. voici en exemple une représentation de notre matrice de comparaison triée par l'algorithme N.-J.




FIGURE 6 – Matrice des distances de Wasserstein Ordonnée par L'algo. N.-J.

3. Résultats

Méthode	Mantel	Pearson
Sans normalisation	Mantel = 0.1589 (p=0.0060) → Faible corrélation positive (p=0.0060) → Faible corrélation positive (p=0.0060)	Pearson = 0.1589 (p=0.0000)
Min-Max (0-1)	Mantel = 0.1589 (p=0.0060) → Faible corrélation positive (p=0.0060) → Faible corrélation positive (p=0.0060)	Pearson = 0.1589 (p=0.0000)
Z-score	Mantel = 0.1589 (p=0.0060) → Faible corrélation positive (p=0.0060) → Faible corrélation positive (p=0.0060)	Pearson = 0.1589 (p=0.0000)
Conversion en rangs	Mantel = 0.3547 (p=0.0000) → Modérée corrélation positive (p=0.0000) → Modérée corrélation positive (p=0.0000)	Pearson = 0.3547 (p=0.0000)

3.1 Analyse descriptive

Nous avons bien trouvé une corrélation entre la matrice issue des distances de wasserstein entre les barcodes des 152 protéines et la matrice cophénique obtenue à partir de l'arbre phylogénétique de référence mais ce résultat était faible :

$r_{Mantel} = 0.1589$ sans normalisation

$r_{Mantel} = 0.3547$ avec normalisation

Alors que l'ordre de grandeur attendu était de 0.8 à 0.9^[3], une différence qui est expliquée dans la section erratum.

4. Discussion

De manière générale, la distance de Wasserstein appliquée aux diagrammes de persistance permet de capturer des similarités structurelles entre protéines, mais elle ne reflète pas nécessairement leur histoire évolutive. Le fait que les deux outliers identifiés correspondent à des neuroglobines de lamproie peut s'expliquer soit par une forte variabilité structurale au sein d'une même espèce, soit par un artefact lié à la qualité des structures PDB disponibles pour ces protéines.

L'arbre obtenu à partir des distances de Wasserstein ne correspond pas à l'arbre phylogénétique pour plusieurs raisons. Tout d'abord, la phylogénie repose sur les séquences en acides aminés, alors que la TDA s'appuie exclusivement sur des motifs géométriques globaux issus des structures tridimensionnelles. Il est donc possible que la structure soit fortement conservée malgré une divergence importante des séquences, ce qui empêche la mise en évidence de signaux évolutifs fins. Par ailleurs, le bruit présent dans les fichiers PDB (résolution variable, modèles incomplets, incertitudes expérimentales) peut perturber les distances de Wasserstein et introduire des différences artificielles dans l'arbre obtenu.

4.2 erratum

Les résultats obtenus en 3 sont incorrects en grande partie à cause de la construction de notre arbre phylogénique. En effet, il recense les codes PDB classés dans l'ordre alphabétique et par espèce. Le but était de ne

pas compter toutes les permutations puisqu'il y a plusieurs matrices cophéniques associées à l'arbre réel et pas une seule liée à un arbre dont le contenu est ordonné alphabétiquement comme nous l'avons fait. Cela explique les écarts de valeurs avec ce que nous attendions lors de la comparaison avec la matrice de Wasserstein. Nous n'avons pas pu corriger cette erreur à temps.


4.3 ouverture, perspectives

L'Analyse Topologique de Données (TDA) par calcul des distances de wasserstein est très gourmand en mémoire avec une complexité en $O(2^n)$ pour la filtration de Vietoris-Rips, puis $O(n^2)$ pour la distance de Wasserstein, à nouveau $O(n^2)$ pour une matrice de comparaisons de distances ce qui nécessite de trouver des compromis entre la taille du jeu de données initiales ou la qualité du traitement des informations. C'est pour cela qu'il est important de comprendre au mieux la TDA afin d'optimiser les calculs.


critiques : Notre travail de comparaison a été réalisé sur des structures figées obtenues depuis PDB soit par cristallographie soit par prédiction Alphafold, et correspondent donc à un état parmi de multiples conformations existantes.

Ces conformations sont disponibles sur [PED](#) pour 6773 protéines, et 1Milion de conformations au total, cela nous permettrait de comparer deux protéines entre elles de manière plus avancée en comparant l'ensemble des appariements possibles de leurs conformations par filtration puis wasserstein et matrice de comparaison.


Or, il faudrait réduire au maximum l'utilisation de Wasserstein et d'analyse matricielle afin de diminuer la complexité :



ici la méthode **WASCO** a été utilisée pour comparer des ensembles de protéines :



L'idéal serait de pouvoir réaliser une filtration avancée qui prend en compte l'ensemble des conformations et retourne un unique vecteur :



avantage : nous pouvons identifier les structures qui persistent d'une conformation à une autre, que les structures soient classées par ordre de conformation de moindre énergie ou par ordre dans le temps, et cela en imaginant :

un nombre de betti β_3 qui identifierait les cavités persistantes entre barcodes de conformations différentes ou plus généralement un nombre de betti à paramètre supplémentaire, si K_i un complexe simplicial on emploie $\beta_{k,1}(K_i)$ pour effectuer les filtrations sur chacun des diagrammes, et $\beta_{k,2}(K_i, K_{i+1})$ pour indiquer si les éléments issus de la filtration i_{eme} sont retrouvés dans la filtration $i+1_{eme}$ quitte à employer un appariement γ ou la distance de wasserstein à ce niveau là. En plus d'identifier la persistance des cavités entre conformations, nous pourrions identifier la persistance de tous les motifs issus de la filtration (cycles, chaînes ...)

5. Conclusion

Dans ce travail, nous avons montré que l'analyse topologique des données constitue un outil pertinent pour étudier la structure géométrique des protéines à partir des positions atomiques carbone alpha. En construisant des complexes de Čech et en analysant leurs diagrammes de persistance, nous avons pu extraire des invariants topologiques robustes décrivant les composantes connexes, les boucles et les cavités caractéristiques des structures protéiques.

L'utilisation de la distance de Wasserstein a permis de quantifier finement la similarité entre protéines, en tenant compte non seulement de la présence de motifs topologiques, mais aussi de leur stabilité. L'application de ces distances à un ensemble de 152 protéines a conduit à une matrice de comparaison exploitable pour des analyses statistiques ultérieures. L'ordonnement obtenu via la Régression Linéaire aux Moindres Carrés (RLMC) a fourni un score cohérent permettant de classer les protéines selon leur proximité topologique. Les tests de significativité et la correction de Bonferroni ont validé la robustesse de cet ordonnancement. Enfin, la construction d'un arbre phylogénétique par l'algorithme Neighbor Joining a offert une représentation synthétique et interprétable des relations entre protéines.

Dans l'ensemble, cette approche combinant TDA, distances topologiques et méthodes statistiques démontre sa capacité à capturer des informations structurales pertinentes, difficiles à obtenir par des méthodes classiques. Elle ouvre la voie à des analyses plus fines, notamment pour la classification fonctionnelle, la détection d'anomalies structurales ou l'étude évolutive des familles protéiques.

Remerciements

Nous remercions nos collègues Romain, Gaspard et Cylia pour leur contribution à la pipeline générale et aux recherches de solutions en travail de groupe, nos superviseurs Philippe Malbos, Celine Brochier Armanet et Jules Fauchon pour leurs conseils avisés, ainsi que l'ensemble de l'équipe pédagogique pour leur soutien.

Références

- [1] Léa Bou Dagher, Dominique Madern, Philippe Malbos, Céline Brochier-Armanet, Faithful Interpretation of Protein Structures through Weighted Persistent Homology Improves Evolutionary Distance Estimation, *Molecular Biology and Evolution*, Volume 42, Issue 2, February 2025
- [2] Chazal F and Michel B (2021) An Introduction to Topological Data Analysis : Fundamental and Practical Aspects for Data Scientists. *Front. Artif. Intell.*
- [3] Bou Dagher L., Madern D., Malbos P., Brochier-Armanet C. Faithful Interpretation of Protein Structures through Weighted Persistent Homology Improves Evolutionary Distance Estimation. *Molecular Biology and Evolution*, Volume 42, Issue 2, February 2025. <https://academic.oup.com/mbe/article/42/2/msae271/7943665>
- [4] Chazal F., Michel B. An Introduction to Topological Data Analysis : Fundamental and Practical Aspects for Data Scientists. *Frontiers in Artificial Intelligence*, 2021. <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2021.667963/full>
- [5] Protein Ensemble Database. <https://proteinensemble.org/>
- [6] Dallago C., et al. bio_embeddings : A Python library for protein embeddings. https://github.com/sacdallago/bio_embeddings
- [7] Nearest-neighbor chain algorithm. Wikipedia. https://en.wikipedia.org/wiki/Nearest-neighbor_chain_algorithm
- [8] Xiaoxi (Leo) Liu. Personal website. <https://personal.science.psu.edu/lxv1/>
- [9] GUDHI library documentation. Wasserstein distance. https://gudhi.inria.fr/python/latest/wasserstein_distance_user.html
- [10] Bou Dagher L. Thesis : Weighted persistent homology for protein structure analysis. <https://theses.hal.science/tel-03131382/document>
- [11] Bou Dagher L. PhD Thesis (2024). <https://theses.hal.science/tel-04984468v1/file/TH2024BOUDAGHERLEA.pdf>
- [12] Biochimie structurale - cours. Université d'Angers. <https://biochimej.univ-angers.fr/Page2/TexteTD/9BioinfoSTRUCTURALE/2BioinformatiqueLicence/1BioinfoLicenceS6.html>
- [13] Cours sur les structures de données en python. Cours de géométrie algorithmique (LIFAPC). <https://perso.liris.cnrs.fr/raphaelle.chaine/COURS/LIFAPC/>
- [14] Topological Data Analysis course (ETH Zurich). Chapter 6 : Persistence and Wasserstein distance. <https://ti.inf.ethz.ch/ew/courses/TDA24/Chapter6.pdf>
- [15] Levenshtein distance. Wikipedia. https://fr.wikipedia.org/wiki/Distance_de_Levenshtein
- [16] Iftimie Dragos Cours de Mesure et Intégration. Université Lyon 1. <https://math.univ-lyon1.fr/~iftimie/enseignement/tmi-2025-poly.pdf>
- [17] Miermont G. Cours d'intégration et probabilités (L3). ENS Lyon. https://perso.ens-lyon.fr/gregory.miermont/L3_integration-probabilites.pdf
- [18] Bernard Yannou - RLMC Full article (HAL archive). <https://hal.science/hal-04476058v1/document>
- [19] National Library of Medicine. Article reference (PMC11058471). <https://pmc.ncbi.nlm.nih.gov/articles/PMC11058471/>
- [20] Rudesh D Toofanny 1, Amanda L Jonsson 1, Valerie Daggett 1. Multidimensional-Embedded. ENS Lyon. <https://pmc.ncbi.nlm.nih.gov/articles/PMC2877366/>